

WOSAC 관점의 궤적 다양성 평가 Metric

핵심 결론

Self-forcing 으로 WOSAC RMM 을 올렸다는 것만으로는 “다양성이 유지되었다” 고 말하기 어렵다. 따라서 메인 평가는 다음 3 개를 함께 보고하는 것이 가장 설득력 있다.

WOSAC RMM ↑ + WOSAC-CES ↓ + WOSAC-CPD preserved

이 자료의 목적

연구팀 내부 공유, 논문 방법론 설명, reviewer response 에서 사용할 수 있도록 WOSAC-CES 와 WOSAC-CPD 를 짧고 명확하게 설명한다.

작성 기준: 사용자 제공 마크다운 원문 및 공개 자료 확인.

주요 근거: Waymo Sim Agents 2025, ICML 2024 Energy Score, NeurIPS 2024 MGF, CAT-K, RoaD.

한 장 요약

최종 추천 metric

WOSAC-CES 는 “실제 데이터 분포를 잘 맞추는가” 를 본다.

WOSAC-CPD 는 “같은 scenario 의 32 개 closed-loop rollout 이 서로 다양한가” 를 본다.

두 metric 은 같은 거리 함수 $D_s(\cdot, \cdot)$ 를 쓰므로 정의가 단순하고, threshold, kernel, bucket 같은 선택지를 거의 만들지 않는다.

Metric	무엇을 평가하나?	방향
WOSAC RMM	closed-loop rollout 이 logged data 관점에서 현실적인가	높을수록 좋음
WOSAC-CPD	같은 history 에서 만든 32 개 rollout 이 서로 다른가	유지 또는 높음
WOSAC-CES	다양성이 현실적인 분포 안에서 유지되는가	낮을수록 좋음
CPD / Pretrain	self-forcing 후 다양성 보존율	1 에 가까울수록 좋음

왜 WOSAC RMM 만으로 부족한가

WOSAC Sim Agents 는 과거 1 초 history 와 map 을 보고, scene 의 모든 agent 에 대해 **32 개의 realistic joint future** 를 제출하는 문제다. 공식 평가는 motion, interaction, map adherence feature 의 likelihood 를 계산한다. 또한 각 history 에는 logged future 가 하나뿐이므로, 32 개 rollout 로 만든 density 아래에서 logged future likelihood 를 평가한다.¹

따라서 RMM 은 현실성을 보는 데 강하지만, 아래 질문을 직접 답하지는 않는다.

RMM 이 직접 답하지 못하는 질문

같은 scenario 에서 생성한 32 개 rollout 이 정말 서로 다른 plausible future 를 나타내는가?

아니면 하나의 안전한 mode 로 모여서 RMM 만 오른 것인가?

Self-forcing 의 목적이 “RMM 향상” 뿐 아니라 “flow matching 의 multi-modality 보존” 이라면, RMM 과 별도의 diversity metric 이 필요하다.

왜 APD/FPD 와 Energy Score 를 결합하는가

APD/FPD 의 장점과 한계

NeurIPS 2024 MGF 는 APD/FPD 를 사용해 generated candidate 들 사이의 pairwise diversity 를 측정했다. 이 방식은 GT 하나와 비교하지 않고, 생성 후보끼리 직접 비교하므로 mode collapse 확인에 유용하다.²

하지만 APD/FPD 만 쓰면 문제가 있다. 궤적이 비현실적으로 멀리 퍼져도 diversity 가 높게 나온다. 즉, **다양성은 보지만 현실적인 다양성인지는 보장하지 않는다.**

¹Waymo Open Dataset, “Sim Agents - 2025”.

²J. Chen et al., “MGF: Mixed Gaussian Flow for Diverse Trajectory Prediction”, NeurIPS 2024.

Energy Score 의 장점

ICML 2024 Energy Score 논문은 Minimum-of-N 계열 평가가 multimodal trajectory distribution 을 잘 못 평가할 수 있다고 지적하고, Energy Score 기반 평가를 제안했다. Energy Score 는 “GT 와의 거리” 와 “sample 끼리의 거리” 를 함께 쓰므로, 단순한 one-best matching 보다 분포 평가에 더 적합하다.³

따라서 최종 선택

Energy Score 구조를 쓰되, 그 안의 pairwise term 을 WOSAC closed-loop rollout diversity 로 분리 해서 보고한다.

이렇게 하면 이론적 근거와 WOSAC 문제 구조를 동시에 만족한다.

기호 정의

기호	의미
$\mathcal{S}$	validation scenario 집합, $\mathcal{S} = \{1, \dots, N\}$
s	scenario index
R	scenario 당 rollout 수. WOSAC 기준 $R = 32$
T	future time step 수. 8 초, 10Hz 이면 $T = 80$
a	agent index
$\mathcal{A}_s$	scenario s 의 평가 대상 agent 집합
r, r'	rollout index
$\hat{\mathbf{p}}_{s,r,a,t}$	생성 rollout 의 (x, y) 위치
$\mathbf{p}_{s,a,t}^{gt}$	logged future 의 (x, y) 위치
$m_{s,a,t}$	valid mask. 유효하면 1, 아니면 0
$c(a)$	agent type. vehicle, pedestrian, cyclist

Step 1. Agent type 별 scale 계산

차량, 보행자, 자전거는 이동 거리 scale 이 다르다. meter 단위 위치 차이를 그대로 쓰면 차량의 다양성이 metric 을 지배할 수 있다. 그래서 validation GT 에서 agent type 별 scale 을 자동 계산한다.

$$\ell_c = \sqrt{\frac{\sum_{s \in \mathcal{S}} \sum_{a: c(a)=c} \sum_{t=1}^T m_{s,a,t} \left\| \mathbf{p}_{s,a,t}^{gt} - \mathbf{p}_{s,a}^0 \right\|_2^2}{\sum_{s \in \mathcal{S}} \sum_{a: c(a)=c} \sum_{t=1}^T m_{s,a,t}} + \varepsilon}$$

여기서 ℓ_c 는 agent type c 의 평균적인 future 이동 scale 이다. 이 값은 사용자가 고르는 threshold 가 아니라, validation GT 에서 자동 계산된다. 그래서 reviewer 입장에서 metric 튜닝 의심이 적다.

Step 2. WOSAC joint rollout distance

scenario s 에서 rollout r 과 r' 사이의 거리를 다음처럼 정의한다.

³N. Shahroudi, M. Lepson, M. Kull, “Evaluation of Trajectory Distribution Predictions with Energy Score”, ICML 2024.

$$D_s(r, r') = \sqrt{\frac{\sum_{a \in \mathcal{A}_s} \sum_{t=1}^T m_{s,a,t} \left\| \frac{\hat{\mathbf{p}}_{s,r,a,t} - \hat{\mathbf{p}}_{s,r',a,t}}{\ell_{c(a)}} \right\|_2^2}{\sum_{a \in \mathcal{A}_s} \sum_{t=1}^T m_{s,a,t} + \varepsilon}}$$

이 거리는 endpoint 만 보지 않고, **8 초 전체 trajectory** 를 본다. 또한 하나의 rollout 안에 있는 모든 agent 를 같이 비교하므로 WOSAC 의 joint future 구조와 맞다.

GT 와 rollout 사이의 거리도 같은 방식으로 정의한다.

$$D_s(r, gt) = \sqrt{\frac{\sum_{a \in \mathcal{A}_s} \sum_{t=1}^T m_{s,a,t} \left\| \frac{\hat{\mathbf{p}}_{s,r,a,t} - \mathbf{p}_{s,a,t}^{gt}}{\ell_{c(a)}} \right\|_2^2}{\sum_{a \in \mathcal{A}_s} \sum_{t=1}^T m_{s,a,t} + \varepsilon}}$$

Metric 1. WOSAC-CPD

WOSAC-CPD 는 Conditional Pairwise Diversity 이다. 같은 scenario 에서 32 개 rollout 이 서로 얼마나 다른지 직접 측정한다.

$$\text{WOSAC-CPD} = \frac{1}{N} \sum_{s \in \mathcal{S}} \frac{2}{R(R-1)} \sum_{1 \leq r < r' \leq R} D_s(r, r')$$

해석

- 높을수록 32 개 rollout 이 서로 다양하다.
- 낮을수록 rollout 들이 비슷해진다. 즉, mode collapse 의심이 있다.
- 단독으로 maximize 하면 안 된다. 비현실적인 궤적도 점수를 올릴 수 있기 때문이다.

그래서 논문에서는 절대값과 pretrain 대비 보존율을 함께 보고하는 것이 좋다.

$$\text{Diversity Preservation Ratio} = \frac{\text{WOSAC-CPD}_{\text{self-forcing}}}{\text{WOSAC-CPD}_{\text{flow-pretrain}}}$$

이 비율이 1 에 가깝거나 1 보다 크면, self-forcing 후에도 flow matching pretrain 의 rollout 다양성이 유지 되었다고 주장하기 좋다.

Metric 2. WOSAC-CES

WOSAC-CES 는 Conditional Energy Score 이다. 낮을수록 좋다.

$$\text{WOSAC-CES} = \frac{1}{N} \sum_{s \in \mathcal{S}} \left[\frac{1}{R} \sum_{r=1}^R D_s(r, gt) - \frac{1}{2R^2} \sum_{r=1}^R \sum_{r'=1}^R D_s(r, r') \right]$$

첫 번째 항은 rollout 들이 logged future 와 얼마나 가까운지 본다.

$$\frac{1}{R} \sum_{r=1}^R D_s(r, gt)$$

두 번째 항은 rollout 들끼리 얼마나 퍼져 있는지 본다.

$$\frac{1}{2R^2} \sum_{r=1}^R \sum_{r'=1}^R D_s(r, r')$$

즉, WOSAC-CES 는 GT 에 가까운 하나의 trajectory 만 좋아하는 metric 이 아니다. **GT 근처의 plausible distribution 을 만들면서 sample diversity 를 유지하는지**를 함께 본다.

논문 표에 넣는 방식

Model	WOSAC RMM ↑	WOSAC-CES ↓	WOSAC-CPD	CPD / Pretrain
Flow Matching Pretrain	기준	기준	기준	1.00
Open-loop Draft FT	비교	비교	비교	비교
Self-forcing FT	상승	개선 또는 유지	유지	약 1 또는 이상

가장 중요한 주장 구조

$RMM_{SF} > RMM_{Pretrain}$: closed-loop realism 향상.

$CPD_{SF} \approx CPD_{Pretrain}$: rollout 다양성 유지.

$CES_{SF} \leq CES_{Pretrain}$ 또는 comparable: 다양성이 현실적인 분포 안에서 유지됨.

왜 RGPD / Precision-Recall / MMD 를 메인으로 쓰지 않는가

RGPD, feature precision/recall, MMD 는 분석용으로는 유용하다. 하지만 메인 metric 으로 쓰기에는 선택지가 많다.

대안 metric	reviewer 가 물을 수 있는 지점
RGPD	realism gate threshold 를 어떻게 정했는가?
Feature PR	feature 와 bucket 을 왜 그렇게 골랐는가?
MMD	kernel bandwidth 를 왜 그렇게 골랐는가?
Novel-realistic rate	novelty threshold 가 결과에 맞춰진 것은 아닌가?

반면 WOSAC-CES / WOSAC-CPD 는 다음 장점이 있다.

- WOSAC 의 32 개 closed-loop rollout 을 그대로 사용한다.
- threshold, kernel, bucket, realism gate 가 없다.
- agent type scale 은 validation GT 에서 자동 계산된다.
- Energy Score 의 이론적 근거와 APD 계열의 직관을 동시에 가진다.

따라서 reviewer 에게 가장 방어하기 쉬운 메인 metric 은 WOSAC-CES 와 WOSAC-CPD 이다.

CAT-K / RoaD 와의 차별성 설명

CAT-K 는 tokenized traffic model 의 open-loop behavior cloning 이 closed-loop simulation 에서 co-variate shift 를 겪는 문제를 줄이기 위한 closed-loop fine-tuning 방법이다. RoaD 도 policy 자신의 closed-loop rollout 을 additional demonstration 으로 활용해 covariate shift 를 줄이는 방향이다. [4,5] 차별점은 다음처럼 정리하는 것이 좋다.

CAT-K 와 RoaD 는 closed-loop covariate shift 완화에 초점을 둔다. 반면 우리는 self-forcing 이 WOSAC RMM 을 향상시키는 동시에, flow matching 모델의 conditional sample diversity 를 보존하는지 WOSAC-CPD 로 평가한다. 또한 generated rollout distribution 이 logged data distribution 과 잘 맞는지 WOSAC-CES 로 평가한다.

논문에 바로 넣기 좋은 문장

We evaluate closed-loop realism using the official WOSAC RMM. Since RMM does not directly quantify conditional sample diversity among the 32 rollouts, we additionally report WOSAC-CPD, a normalized pairwise diversity metric computed over closed-loop joint rollouts from the same scenario. To assess whether diversity is preserved within the logged data distribution rather than through unrealistic dispersion, we also report WOSAC-CES, an Energy Score-style distributional metric using the same WOSAC joint rollout distance.

최종 정리

최종 추천

WOSAC RMM + WOSAC-CES + WOSAC-CPD

RMM 은 현실성을, CPD 는 32 개 rollout 의 조건부 다양성을, CES 는 데이터 분포 보존성을 본다. 이 조합은 “self-forcing 이 RMM 만 올린 것이 아니라 flow matching 의 multimodal generation 성질을 망가뜨리지 않았다” 는 주장을 가장 간단하고 방어 가능하게 만든다.

References

- [1] Waymo Open Dataset. *Sim Agents - 2025*. Key facts used: 32 realistic joint futures, density-based evaluation, motion / interaction / map adherence features.
- [2] Shahroudi, N., Lepson, M., Kull, M. *Evaluation of Trajectory Distribution Predictions with Energy Score*. ICML 2024, PMLR 235:44322-44341.
- [3] Chen, J., Cao, J., Lin, D., Kitani, K., Pang, J. *MGF: Mixed Gaussian Flow for Diverse Trajectory Prediction*. NeurIPS 2024.
- [4] Zhang, Z. et al. *Closed-Loop Supervised Fine-Tuning of Tokenized Traffic Models*. arXiv:2412.05334 / CVPR 2025.
- [5] Garcia-Cobo, G. et al. *RoaD: Rollouts as Demonstrations for Closed-Loop Supervised Fine-Tuning of Autonomous Driving Policies*. arXiv:2512.01993.
- [6] User-provided markdown text, “WOSAC Conditional Energy Score with Pairwise Diversity” draft.